

Exam 5 - 2021

שאלה 1

נתונות שלוש תמונות: A , B ו- C . כל התמונות בגודל $16 \times 16 \times 3$, ומתקיים $C = A + B$. כמו כן, נתונה רשת נוירונים f . העברנו את התמונה A ברשת f וחישובנו את $f(A)$. באותו אופן, עבור התמונה B חישובנו את $f(B)$. נרצה לחשב את $f(C)$ מבלי להריץ שוב את הרשת f , אלא רק בעזרת $f(A)$ ו- $f(B)$. בכל אחד מהסעיפים הבאים מתוארת רשת f אחרת. לכל רשת שכזו, סמנו כיצד נוכל לחשב את $f(C)$.

שימו לב, "·" הוא כפל איבר-איבר (pointwise multiplication).

Option 1	$f(C) = f(A) \cdot f(B)$
Option 2	$f(C) = f(A) + f(B)$
Option 3	$f(C) = \frac{f(A) \cdot f(B)}{2}$
Option 4	$f(C) = \frac{f(A) + f(B)}{2}$
Option 5	$f(C) = \text{ReLU}(f(A) \cdot f(B))$
Option 6	$f(C) = \text{ReLU}(f(A) + f(B))$
Option 7	לא ניתן לחשב מבלי להעביר את התמונה C ברשת

סעיף א

f :

- Input layer of size $16 \times 16 \times 3$
- Convolution layer, kernel size = 3×3 , stride = 2, output channels = 16, no bias
- Convolution layer, kernel size = 3×3 , stride = 2, output channels = 32, no bias
- Fully connected layer, output channels = 128, no bias
- Fully connected layer, output channels = 10, no bias

סעיף ב

f :

- Input layer of size $16 \times 16 \times 3$
- Convolution layer, kernel size = 3×3 , stride = 1, output channels = 16, no bias
- Average pooling layer, window size = 2×2 , stride = 2
- Convolution layer, kernel size = 3×3 , stride = 1, output channels = 32, no bias
- Average pooling layer, window size = 2×2 , stride = 2
- Fully connected layer, output channels = 128, no bias
- Fully connected layer, output channels = 10, no bias

סעיף ג

f :

- Input layer of size $16 \times 16 \times 3$
- Convolution layer, kernel size = 3×3 , stride = 1, output channels = 16, no bias
- Max pooling layer, window size = 2×2 , stride = 2
- Convolution layer, kernel size = 3×3 , stride = 1, output channels = 32, no bias
- Max pooling layer, window size = 2×2 , stride = 2
- Fully connected layer, output channels = 128, no bias
- Fully connected layer, output channels = 10, no bias

סעיף ד

f :

- Input layer of size $16 \times 16 \times 3$
- Convolution layer, kernel size = 3×3 , stride = 2, output channels = 16, no bias
- ReLU activation layer
- Convolution layer, kernel size = 3×3 , stride = 2, output channels = 32, no bias
- ReLU activation layer
- Fully connected layer, output channels = 128, no bias
- ReLU activation layer
- Fully connected layer, output channels = 10, no bias

תשובות

סעיף א – option 2

מדובר ברשת לינארית, ולכן אפשר להתייחס אליה ככפל מטריצה אחד ששומרת על דיסטריבוטביות.

סעיף ב - option 2

מדובר ברשת לינארית, ולכן אפשר להתייחס אליה ככפל מטריצה אחד ששומרת על דיסטריבוטביות.

סעיף ג – option 7

מדובר ברשת לא לינארית, ולכן לא נוכל לחשב את $f(C)$ מבלי להעביר את C ברשת.

סעיף ד – option 7

מדובר ברשת לא לינארית, ולכן לא נוכל לחשב את $f(C)$ מבלי להעביר את C ברשת.

שאלה 2

אימנו רשת נוירונים g , בעזרת אלגוריתם SGD, על $\hat{S} = \{(x_i, y_i)\}$, כאשר x_i הן תמונות בגודל $32 \times 32 \times 3$, ו- y_i הן הקטגוריות (labels)

נרצה לאמן רשת חדשה f , בעזרת אלגוריתם SGD, אשר תחקה את הרשת g .

באילו מפונקציות ה-loss הבאות נוכל להשתמש? סמנו את כל התשובות הנכונות.

שימו לב, I היא פונקציית אינדיקטור (indication function) המקיימת:

$$I(\text{statement}) = \begin{cases} 1, & \text{if statement} = \text{True} \\ 0, & \text{if statement} = \text{False} \end{cases}$$

$L(f, S) = \frac{1}{ S } \sum_i \ f(x_i) - g(x_i)\ ^2$	Option 1
$L(f, S) = \frac{1}{ S } \sum_i \ f(x_i) - g(x_i)\ $	Option 2
$L(f, S) = \frac{1}{ S } \sum_i (f(x_i) - g(x_i))$	Option 3
$L(f, S) = \frac{1}{ S } \sum_i I(f(x_i) \neq g(x_i))$	Option 4
$L(f, S) = \frac{1}{ S } \sum_i I(f(x_i) < g(x_i))$	Option 5
$L(f, S) = \frac{1}{ S } \sum_i I(f(x_i) = g(x_i))$	Option 6

תשובות:

1-2. $g(x_i)$ מספקת לנו את ה-label, כלומר וקטור. על פונקציית ה-loss שלנו להיות גזירה, אחרת לא נוכל להשתמש באלגוריתם המבוסס על gradient descent, ולכן תשובות 1-2 נכונות. תשובה 3 אכן גזירה אך לא תתכנס לפתרון נכון ולכן אינה תשובה נכונה.

שאלה 3

בכל אחד מהסעיפים הבאים, מתוארת רשת נוירונים f . חשבו את מספר הפרמטרים ברשת.

סעיף א

f :

- Input layer of size $128 \times 128 \times 1$
- Convolution layer, kernel size = 5×5 , stride = 2, output channels = 10, no bias
- ReLU activation layer
- Convolution layer, kernel size = 5×5 , stride = 2, output channels = 10, no bias
- ReLU activation layer

סעיף ב

f :

- Input layer of size $128 \times 128 \times 1$
- Convolution layer, kernel size = 5×5 , stride = 1, output channels = 10, no bias
- ReLU activation layer
- Max pooling layer, window size = 2×2 , stride = 2
- Convolution layer, kernel size = 5×5 , stride = 1, output channels = 10, no bias
- ReLU activation layer
- Max pooling layer, window size = 2×2 , stride = 2

סעיף ג

f :

- Input layer of size $64 \times 64 \times 1$
- Convolution layer, kernel size = 5×5 , stride = 2, output channels = 10, no bias
- ReLU activation layer
- Convolution layer, kernel size = 5×5 , stride = 2, output channels = 10, no bias
- ReLU activation layer

תשובות:

סעיף א – 2750.

גודל קרנל בשכבת קונבולוציה הוא:

$$in_channels \times out_channels \times kernel_size \times kernel_size$$

ולכן עבור שכבת הקונבולוציה הראשונה נקבל: $1 \times 10 \times 5 \times 5 = 250$

ועבור שכבת הקונבולוציה השנייה: $10 \times 10 \times 5 \times 5 = 2500$

מכיוון שלא היה bias בשכבות הקונבולוציה, אלו כל הפרמטרים של הרשת.

סעיף ב – 2750.

ההבדל היחיד מהרשת של סעיף א הוא שהחלפנו את striden בשכבת הקונבולוציה בשכבות max pooling. לשכבות אלו אין פרמטרים נלמדים ולכן מספר הפרמטרים ברשת לא השתנה.

סעיף ג – 2750.


ההבדל היחיד מהרשת של סעיף א הוא ששינינו את גודל האינפוט של הרשת. היות ומספר הערוצים נשאר זהה, 1, כמות הפרמטרים לא השתנתה. גודל הקרנל תלוי רק במספר הערוצים ולא ברוחב וגובה התמונה.

שאלה 4

אימנו את רשת הנוירונים f המתוארת למטה. פרטי האימון:

- Optimizer: SGD
- Learning rate: 0.001
- Batch size: 256
- Number of epochs: 200

בגרף הבא ניתן לראות את ה- train loss ואת validation loss לאורך תהליך האימון. מה מבין הפעולות הבאות נהיה מעוניינים לעשות על מנת לשפר את אימון הרשת. סמנו את כל התשובות הנכונות.



אפשרויות:

1. להקטין את זמן האימון ל- 100 epochs.
2. להגדיל את זמן האימון ל- 300 epochs.
3. להקטין את גודל ה- batch size.
4. להוסיף שכבות dropout לרשת.
5. להוסיף לאימון שיקופים (flip) וסיבובים קטנים ($\pm 5^\circ$) של התמונות.
6. להגדיל את מספר ה- output channels בשכבות הקונבולוציה.

תשובות

1, 4, 5.

הסבר: מדובר ברשת שסובלת מoverfitting.

- ניתן לראות בגרף האימון כי באפוק 100 הרשת ביצעה פחות אוברפיטינג, וככל שהתקרבו לאפוק 200, הtrain loss ירד, ואילו validation loss עלה, ולכן עצירה ב100 epoch היתה מחזירה לנו רשת טובה יותר.
- הקטנת הbatch size רק עשויה לגרום לכך שנקבל פחות וריאציה בכל batch ולכן כמובן שלא נשתפר בעקבות כך.
- הוספת שכבות dropout הוצעה כדרך להתמודד עם אוברפיטינג.
- הוספת שיקופים וסיבובים: מדובר באוגמנטציות, שיטה נוספת שלמדנו להתמודדות עם אוברפיטינג.
- הגדלת מספר הoutput channels בשכבות הקונבולוציה: ראינו כי רשתות גדולות יותר עשויות לסבול יותר מאוברפיטינג, ולכן בהינתן רשת שבוודאי סובלת מאוברפיטינג, לא נרצה להגדיל אותה עוד.

שאלה 5

נתונות שתי תמונות, כאשר המטריצה הפונדמנטלית F בין התמונה הראשונה לשניה היא:

$$F = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & -1 \\ 0 & 1 & 0 \end{pmatrix}$$

סעיף A -

אילו מהנקודות הבאות תהיינה על הקו האפיפולרי בתמונה השניה, המתאים לנקודה $x = (0,0)$ בתמונה הראשונה? סמנו את כל התשובות הנכונות.

סעיף B -

אילו מהנקודות הבאות תהיינה על הקו האפיפולרי בתמונה השניה, המתאים לנקודה $x = (1,1)$ בתמונה הראשונה? סמנו את כל התשובות הנכונות.

סעיף C -

אילו מהנקודות הבאות תהיינה על האפיפול בתמונה השנייה? סמנו את כל התשובות הנכונות.

(0,1)	(-1,0)	(0,0)	(1,-1)	(-1,-1)	(1,1)	אף אחת מהנקודות
-------	--------	-------	--------	---------	-------	-----------------

תשובות

סעיף א – הקו האפיפולרי הוא $v=0$ ולכן: $(-1,0)$, $(0,0)$

סעיף ב – הקו האפיפולרי הוא $u=-1$ ולכן: $(-1,0)$, $(-1,-1)$

סעיף ג – החיתוך בין הקווים האפיפולריים: $(-1,0)$

שאלה 6

רכב משטרה חונה צילם בוידאו מכונית שעקפה אותו. רוחב המכונית היה 110 פיקסלים כאשר היא היתה במקום שהיה ידוע מראש כמרוחק 100 מטר ממכונית המשטרה. בצילום שנלקח 0.1 שניות אח"כ, רוחב המכונית היה 100 פיקסלים. מה היתה מהירות המכונית? סמנו את התשובה הקרובה ביותר.

תשובה

100 מטר לשניה.

נוסחת הTTC היא:

$$\frac{x_2}{x_2 - x_1} = \frac{Z_1}{Z_1 - Z_2}$$

כאשר $Z_2 - Z_1$ הוא הביטוי שמעניין אותנו: כמה זזה המכונית ב0.1 שניות. מתוך כך נוכל לחשב כמה היא זזה בשניה.

נציב:

$$\frac{100}{100 - 110} = \frac{100}{Z_1 - Z_2}$$

↓

$$-10 = \frac{100}{Z_1 - Z_2}$$

↓

$$Z_2 - Z_1 = \frac{100}{10} = 10$$

ולכן המכונית זזה 10 מטר ב0.1 שניות, כלומר 100 מטר בשניה.